Analisi dei test effettuati

Test di Stefano Biddau su MNIST con Alberi decisionali

Cenni teorici Alberi Decisionali

DEFINIZIONE:

L'albero decisionale è un algoritmo di tipo supervisionato usato nel ML.
È un modello predittivo che può essere usato sia per casi di classificazione sia per casi di regressione. Ciò significa che l'output che andrà a prevedere il modello sarà una variabile categorica (per esempio una binaria SI/NO) oppure una quantità continua.
Gli alberi decisionali sono gli algoritmi più comuni perché sono molto veloci e sopratutto semplici da interpretare. Questo è fondamentale perché in alcuni settori in cui si può preferire una maggiore semplicità di comprensione ad una maggiore accuratezza del modello.

FUNZIONAMENTO

In questo algoritmo i dati che io do come input vengono continuamente splittati in base a determinati criteri. Due concetti chiave per comprender il loro funzionamento sono i nodi e le foglie.
- I nodi: sono i luoghi in cui in base a certe regole i dati vengono splittati;
- Le foglie: sono i risultati intermedi o finali ossia i luoghi in cui finiscono i dati una volta splittati

Ma in base a quali criteri i dati vengono separati?

PRINCIPALI IPER-PARAMETRI DEL MODELLO

Vediamo quali sono (per la mia esperienza) i principali parametri o iper-parametri di un modello Decision Tree, prendendo in considerazione l'implementazione della libreria scikit-learn in Python.

Tra i parametri da tenere fortemente in considerazione c'è la metrica di splitting, che, misurando la qualità dello split, separerà i dati. Questo parametro si chiama **criterion** e dipende dal task che si vuole svolgere.
Per quanto riguarda il problema della classificazione, può avere "gini" e "entropy" come possibili valori. "Gini" fa riferimento all'impurità di Gini, mentre "entropy" all'informazione gain, basato sul concetto di entropia nella teoria dell'informazione.

Un altro parametro da controllare è quello che si chiama **max_depth**: questo indica quanto profondo sarà l'albero. Più profondo sarà l'albero, più split farà e più sarà preciso sui dati di addestramento. Questo però non vuol dire che se è più preciso sui dati di train il modello sarà in grado di generalizzarli bene, anzi più sarà profondo più sarà profondo più preciso sarà sui dati di train e mono probabilmente sarà in grado di generalizzare su dati nuovi.
Una maggior profondità quindi rischia di far cadere in quel fenomeno chiamato overfitting ovvero un'ottima capacità sul train ma una pessima sul test che si traduce in un incapacità di generalizzare su nuovi dati.

Un altro parametro che può portare overfitting è **min_samples_leaf**, ovvero quanti esemplari minimi di osservazioni possono finire nelle foglie finali. Un numero basso vorrà dire anche in questo caso una maggior precisione sul train, che potrà portare di nuovo ad una scarsa accuratezza sul test. Questo perché si andranno ad identificare i casi più specifici e non quelli generali.

Altro iper-parametro importante è **max_features**. Questo parametro ci da la possibilità di scegliere in numero di variabili da utilizzare per trovare il best split. È inizializzato a None quindi verrà cercato su tutte le variabili o sulla radice quadrata del numero delle variabili (se ne ho 16, lo cerco su 4)

PRO E CONTRO DELL'ALBERO DECISIONALE

PRO
- Molto semplice da capire e interpretare;
- Può lavorare su dati numerici e categorici contemporaneamente;
- Non richiede moltissimi dati;
- Performa bene sia sui pochi dati che su grandi dataset

CONTRO
- Non è un modello robusto, quindi un piccolo cambiamento nel training può comportare un gradissimo cambiamento nella prediction
- Altissimo rischio di overfitting

TEST EFFETTUATI

MNIST

Eseguendo lo script per l'ottimizzazione degli iper parametri salta all'occhio che nelle prime 10 posizioni delle simulazioni effettuate con i migliori responsi in termini di accuratezza troviamo principalmente 4 tipi di profondità: (11, 13, 15, 17)
Testiamo anche la profondità limite scelta che è 21 e poi testiamo una profondità che sfora il range prestabilito ossia 25.

1° Blocco di test (Aumento profondità, c: Gini, mf: None, msl: 1)

Indice test	Profondità massima	Criterio	Max features	Min samples leaf	Acc Train	Acc Test	Differenza MSE	Over-fit
1	**11**	**Gini**	**None**	**1**	**92,76%**	**87,49%**	**0,84**	**NO**
2	13	Gini	None	1	96,50%	88,03%	1,43	NO
3	15	Gini	None	1	98,44%	88,20%	1,71	NO
4	**17**	**Gini**	**None**	**1**	**99,01%**	**88,21%**	**1,83**	**NO**
5	21	Gini	None	1	99,57%	88,02%	1,94	SI
6	25	Gini	None	1	99,73%	88,01%	1,99	SI

Da questi primi 6 test si evince che all'aumentare della profondità massima dell'albero decisionale aumenta la percentuale di accuratezza sul set di train, mentre aumenta più lentamente quella su set di test che mantiene sempre una differenza di circa 10 punti percentuali, a partire dalla profondità di 21 l'accuratezza sul set di test inizia addirittura a calare avviandosi verso l'overfitting.Il miglior risultato ottenuto è il **test 4** in termini di percentuale di accuratezza più alta sul set di test, tuttavia è da considerare ottimo anche il **test 1** in cui la differenza tra l'errore sul set di train e l'errore sul set di test è davvero minima.

2° Blocco di test (Aumento profondità, c: Gini, mf: None, msl: 25)

Indice test	Profondità massima	Criterio	Max features	Min samples leaf	Acc Train	Acc Test	Differenza MSE	Over-fit
1	11	Gini	None	25	87,99%	85,79%	0,23	NO
2	13	Gini	None	25	88,53%	86,04%	0,32	NO
3	15	Gini	None	25	88,61%	86,13%	0,32	NO
4	17	Gini	None	25	88,61%	86,13%	0,32	NO
5	21	Gini	None	25	88,63%	86,15%	0,33	NO
6	**25**	**Gini**	**None**	**25**	**88,63%**	**86,16%**	**0,32**	**NO**
7	30	Gini	None	25	88,63%	86,15%	0,32	NO
8	35	Gini	None	25	88,63%	86,15%	0,32	NO

Per questi 8 test effettuati raccogliamo degli ottimi risultati. Aumentando a 25 il numero di esemplari minimi che finiscono nelle foglie, abbiamo trovato una combinazione di parametri che stabilizza dopo una certa profondità i valori di accuratezza sia sul set di train che sul set di test, che oltretutto mostrano avere dei livelli di accuratezza in termini di percentuale molto vicini. Questa cosa ci garantisce l'assenza di overfitting. Il miglior risultato ottenuto è il **test 6** in termini di percentuale di accuratezza più alta sul set di test ma anche per differenza tra l'errore sul set di train e di test che è minima . Unica pecca data l'estrema semplicità del dataset le percentuali di accuratezza sono leggermente basse per gli standard.

3° Blocco di test (aumento profondità, c: Gini, mf: None, msl: 50)

Indice test	Profondità massima	Criterio	Max features	Min samples leaf	Acc Train	Acc Test	Differenza MSE	Over-fit
1	11	Gini	None	50	85,64%	84,53%	0,05	NO
2	**13**	**Gini**	**None**	**50**	**85,87%**	**84,66%**	**0,08**	**NO**
3	15	Gini	None	50	85,87%	84,65%	0,08	NO
4	17	Gini	None	50	85,87%	84,66%	0,08	NO
5	21	Gini	None	50	85,87%	84,66%	0,08	NO
6	25	Gini	None	50	85,87%	84,66%	0,08	NO

Per questi 6 test effettuati notiamo un'analogia col il 2° blocco di test effettuati, in cui dopo aver raggiunto al **test 2** il miglior risultato sia in termini di percentuali sull'accuratezza del set di test, questo si stabilizza. Unica pecca data l'estrema semplicità del dataset le percentuali di accuratezza sono leggermente basse per gli standard.

*Ripetiamo adesso i 3 blocchi di test effettuati cambiando il parametro **max_features** da **None** (standard) a **0,5** e vediamo come si comporta il classificatore.*

4° Blocco di test (Aumento profondità, c: Gini, mf: 0,5, msl: 1)

Indice test	Profondità massima	Criterio	Max features	Min samples leaf	Acc Train	Acc Test	Differenza MSE	Over-fit
1	**11**	**Gini**	**0,5**	**1**	**92,59%**	**86,94%**	**0,86**	**NO**
2	13	Gini	0,5	1	95,80%	87,46%	1,35	NO
3	15	Gini	0,5	1	98,22%	87,88%	1,62	NO
4	**17**	**Gini**	**0,5**	**1**	**99,01%**	**88,51%**	**1,68**	**NO**
5	21	Gini	0,5	1	99,51%	87,34%	1,97	SI
6	25	Gini	0,5	1	99,68%	87,57%	1,96	SI
7	30	Gini	0,5	1	99,87%	87,36%	2.1	SI

I risultati ottenuto da questi 7 test si mostrano in linea con l'andamento del 1° blocco di test effettuati. Il miglior risultato ottenuto è il **test 4** in termini di percentuale di accuratezza più alta sul set di test, tuttavia è da considerare ottimo anche il **test 1** in cui la differenza tra l'errore sul set di train e l'errore sul set di test è davvero minima. I valori ottenuti sono più alti anche se di poco rispetto a quelli ottenuti dal 1° blocco di test di sotto mostrata una comparazione:

- 4° blocco test 4: **88,51%**
- 1° blocco test 4: **88,21 %**

Come per il primo blocco anche per questi test dopo la soglia di profondità 17 l'accuratezza sul set di test inizia a calare in termini di percentuale avvicinandosi verso l'overfitting.

5° Blocco di test (Aumento profondità, c: Gini, mf: 0,5, msl: 25)

Indice test	Profondità massima	Criterio	Max features	Min samples leaf	Acc Train	Acc Test	Differenza MSE	Over-fit
1	11	Gini	0,5	25	87,12%	85,30%	0,25	NO
2	13	Gini	0,5	25	87,67%	85,26%	0,30	NO
3	15	Gini	0,5	25	88,00%	85,60%	0,31	NO
4	17	Gini	0,5	25	88,18%	85,95%	0,36	NO
5	21	Gini	0,5	25	87,95%	85,37%	0,35	NO
6	25	Gini	0,5	25	88,27%	85,83%	0,37	NO
7	**30**	**Gini**	**0,5**	**25**	**88,19%**	**86,00%**	**0,38**	**NO**
8	**35**	**Gini**	**0,5**	**25**	**88,19%**	**86,00%**	**0,38**	**NO**

I risultati ottenuti da questo blocco di 8 test evidenziano un andamento altalenante delle percentuali di accuratezza sia sul set di test che sul set di train. All'aumentare della profondità dell'albero l'accuratezza sul set di train cresce e decresce fino ad arrivare alla profondità di 30 oltre il quale il tasso di accuratezza sui set si stabilizza. Infatti i **test 7,8** sono i migliori ottenuti in termini di punti percentuali, da considerare anche il **test 1** che mostra una differenza di errore tra i due set di dati veramente minima con dei valori percentuali di accuratezza rispettabili.

Rispetto al 2° blocco di test i risultati sono lievemente più bassi in termini di percentuali di accuratezza, la cosa che li accomuna è che entrambe i set di parametri portano dopo una certa profondità ad una stabilizzazione dei valori.

6° Blocco di test (Aumento profondità, c: Gini, mf: 0,5, msl: 50)

Indice test	Profondità massima	Criterio	Max features	Min samples leaf	Acc Train	Acc Test	Differenza MSE	Over-fit
1	11	Gini	0,5	50	84,45%	83,44%	0,20	NO
2	13	Gini	0,5	50	84,62%	83,63%	0,20	NO
3	15	Gini	0,5	50	84,86%	82,99%	0,33	NO
4	**17**	**Gini**	**0,5**	**50**	**84,98%**	**84,09%**	**0,012**	**NO**
5	21	Gini	0,5	50	84,82%	83,40%	0,20	SI
6	25	Gini	0,5	50	84,83%	82,78%	0,33	SI

Da questi 6 test notiamo un comportamento estremamente peggiore rispetto al 3° blocco di test con max_features: None in cui addirittura si va in overfitting a partire da una profondità di 21 dell'albero, **il test 4** risulta il migliore sia in termini di percentuale di accuratezza sia in termini di differenza di errore tra il set di trai e quello di test che risulta essere il più piccolo fini ora ottenuto tuttavia, le percentuali di accuratezza sono molto basse per il dataset MNIST.

*Ora ripetiamo questi 6 blocca di test cambiando il **criterio** da **Gini** -> **Entropy** e vediamo se otteniamo migliori risultati*

7° Blocco di test (Aumento profondità, c: Entropy, mf: None, msl: 1)

Indice test	Profondità massima	Criterio	Max features	Min samples leaf	Acc Train	Acc Test	Differenza MSE	Over-fit
1	11	Entropy	None	1	94,16%	88,08%	0,95	NO
2	**13**	**Entropy**	**None**	**1**	**98,19%**	**89,09%**	**1,50**	**NO**
3	15	Entropy	None	1	99,52%	88,75%	1,74	SI
4	17	Entropy	None	1	99,88%	88,61%	1,92	SI
5	21	Entropy	None	1	100%	88,63%	1,91	SI
6	25	Entropy	None	1	100%	88,64%	1,92	SI

Dopo questo gruppo di 6 test possiamo evincere che Il criterio Entropy rispetto al Gini fa lievitare di molto sia l'accuratezza sul set di train che sul set di test. Registriamo infatti con il **test 2** i migliori risultati fin ora ottenuti con un accuratezza sul set di test che sfiora il 90%.
Tuttavia notiamo anche in negativo che il criterio entropy accelera il processo di raggiungimento dell' overfitting infatti come si può vedere con il **test 5** e il **test 6** la percentuale di accuratezza sul set di train è pari al **100**% che è sinonimo di un **modello inutile.**

8° Blocco di test (Aumento profondità, c: Entropy, mf: None, msl: 25)

Indice test	Profondità massima	Criterio	Max features	Min samples leaf	Acc Train	Acc Test	Differenza MSE	Over-fit
1	11	Gini	None	25	88,81%	86,52%	0,30	NO
2	**13**	**Gini**	**None**	**25**	**89,32%**	**86,86%**	**0,36**	**NO**
3	15	Gini	None	25	89,34%	86,86%	0,36	NO
4	17	Gini	None	25	89,34%	86,86%	0,36	NO
5	21	Gini	None	25	89,34%	86,85%	0,37	NO
6	25	Gini	None	25	89,34%	86,85%	0,37	NO

Da questi 6 test si evince che dopo aver raggiunto un picco massimo (**test 2**) sia in termini di accuratezza sul set di test e di train, sia per la differenza di errore trai i due set, i valori di accuratezza si stabilizzano all'aumentare della profondità evitando di andare in overfitting.
Il criterio **entropy** a differenza di **Gini** ci ha permesso di stabilizzare i valori di accuratezza sui set di dati a partire da una profondità più piccola.

9° Blocco di test (Aumento profondità, c: Entropy, mf: None, msl: 50)

Indice test	Profondità massima	Criterio	Max features	Min samples leaf	Acc Train	Acc Test	Differenza MSE	Over-fit
1	**11**	**Entropy**	**None**	**50**	**86,19%**	**84,76%**	**0.17**	**NO**
2	13	Entropy	None	50	86,31%	84,72%	0,21	NO
3	15	Entropy	None	50	86,31%	84,72%	0,21	NO
4	17	Entropy	None	50	86,31%	84,72%	0,21	NO
5	21	Entropy	None	50	86,31%	84,72%	0,21	NO
6	25	Entropy	None	50	86,31%	84,72%	0,21	NO

Da questi 6 test effettuati si evince come per il medesimo blocco (n°6) di come il parametro **min_seamples_leaf** settato a **50** stabilizzi i valori di accuratezza sia sul set di trai che sul set di test dopo una certa profondità, il criterio entropy anche in questo caso svolge un ruolo sia di aumento del valore in percentuale su tutti e due i set sia stabilizzando prima il modello dopo i miglior risultato ottenuto nel **test 1.**

10° Blocco di test (Aumento profondità, c: Entropy, mf: 0,5, msl: 1)

Indice test	Profondità massima	Criterio	Max features	Min samples leaf	Acc Train	Acc Test	Differenza MSE	Over-fit
1	11	Entropy	0,5	1	93,63%	87,50%	1,07	NO
2	13	Entropy	0,5	1	97,76%	87,95%	1,61	NO
3	**15**	**Entropy**	**0,5**	**1**	**99,41%**	**88,39%**	**1,82**	**NO**
4	17	Entropy	0,5	1	99,81%	88,27%	1,97	NO
5	21	Entropy	0,5	1	99,96%	88,35%	1,99	SI
6	25	Entropy	0,5	1	100%	88,12%	2,01	SI

Da questo gruppo di 6 test effettuati si evince un comportamento analogo al blocco i test effettuato con criterio **Gini**, con l'unica differenza che abbiamo un aumento dei valori di accuratezza su entrambe i set di dati, ma anche un avvicinamento più veloce all'overfitting all'aumentare della profondità dell'albero, infatti dopo aver raggiunto i risultati migliori con il **test 3** il modello diventa inutilizzabile.

11° Blocco di test (Aumento profondità, c: Entropy, mf: 0,5, msl: 25)

Indice test	Profondità massima	Criterio	Max features	Min samples leaf	Acc Train	Acc Test	Differenza MSE	Over-fit
1	11	Entropy	0,5	25	88,26%	85,95%	0,38	NO
2	13	Entropy	0,5	25	89,05%	86,10%	0,52	NO
3	**15**	**Entropy**	**0,5**	**25**	**88,56%**	**86,42%**	**0,35**	**NO**
4	17	Entropy	0,5	25	88,56%	85,97%	0,36	NO
5	21	Entropy	0,5	25	88,85%	86,38%	0,41	SI
6	25	Entropy	0,5	25	88,85%	86,38%	0,41	SI

Questo gruppo di 6 test mostra delle analogie con il blocco di test effettuati con gli stessi parametri e criterio **Gini**, ormai sembra di aver compreso che il criterio **Entropy** fa lievitare il tasso di accuratezza sui set sia di trai che di test. Per questo blocco il miglior risultato è stato ottenuto dal **test 3** gli altri ci mostrano un andamento per quanto riguarda la percentuale di accuratezza altalenante fino a stabilizzarsi a partire da una profondità di 21 dell'albero.

12° Blocco di test (Aumento profondità, c: Entropy, mf: 0,5, msl: 50)

Indice test	Profondità massima	Criterio	Max features	Min samples leaf	Acc Train	Acc Test	Differenza MSE	Over-fit
1	11	Entropy	0,5	50	85,20%	83,76%	0,34	NO
2	13	Entropy	0,5	50	86,16%	84,74%	0,27	NO
3	15	Entropy	0,5	50	85,52%	84,73%	0,23	NO
4	17	Entropy	0,5	50	85,57%	84,57%	0,06	NO
5	**21**	**Entropy**	**0,5**	**50**	**85,73%**	**84,77%**	**0,13**	**SI**
6	25	Entropy	0,5	50	85,73%	84,77%	0,13	SI

Questo gruppo di 6 test mostra un comportamento molto diverso da quello analogo (6° Blocco), qui notiamo di come ci sia una costante crescita dei valori di accuratezza sul set di test, i migliori risultati si ottengono con il **test 5** dopodiché i valori di ottimali si stabilizzano.

Possiamo stilare una lista di 3 test, quelli con i migliori risultati ottenuti in termini di percentuale di accuratezza sul set di test:

1) Blocco 7 - Test 2: Test del 2022-10-31 12:46:39
2) Blocco 4 - Test 4: Test del 2022-10-30 17:34:43
3) Blocco 10 - Test 3: Test del 2022-11-01 17:24:20

1) **Test del 2022-10-31 12:46:39 MNIST con Decision Tree (profondità: 13, c: entropy, mf: None, msl:1)**

Report di classificazione

	precision	recall	f1-score	support
0	0.93	0.93	0.93	980
1	0.96	0.97	0.97	1135
2	0.87	0.88	0.88	1032
3	0.86	0.86	0.86	1010
4	0.88	0.87	0.87	982
5	0.84	0.86	0.85	892
6	0.92	0.90	0.91	958
7	0.92	0.90	0.91	1028
8	0.84	0.85	0.85	974
9	0.86	0.87	0.86	1009
accuracy			0.89	10000
macro avg	0.89	0.89	0.89	10000
weighted avg	0.89	0.89	0.89	10000

Dal report di classificazione notiamo che il nostro classificatore ottiene i migliori risultati classificando la **classe 1-> cifra 1** e i peggiori risultati di classificazione con la **classe 8 -> cifra 8**

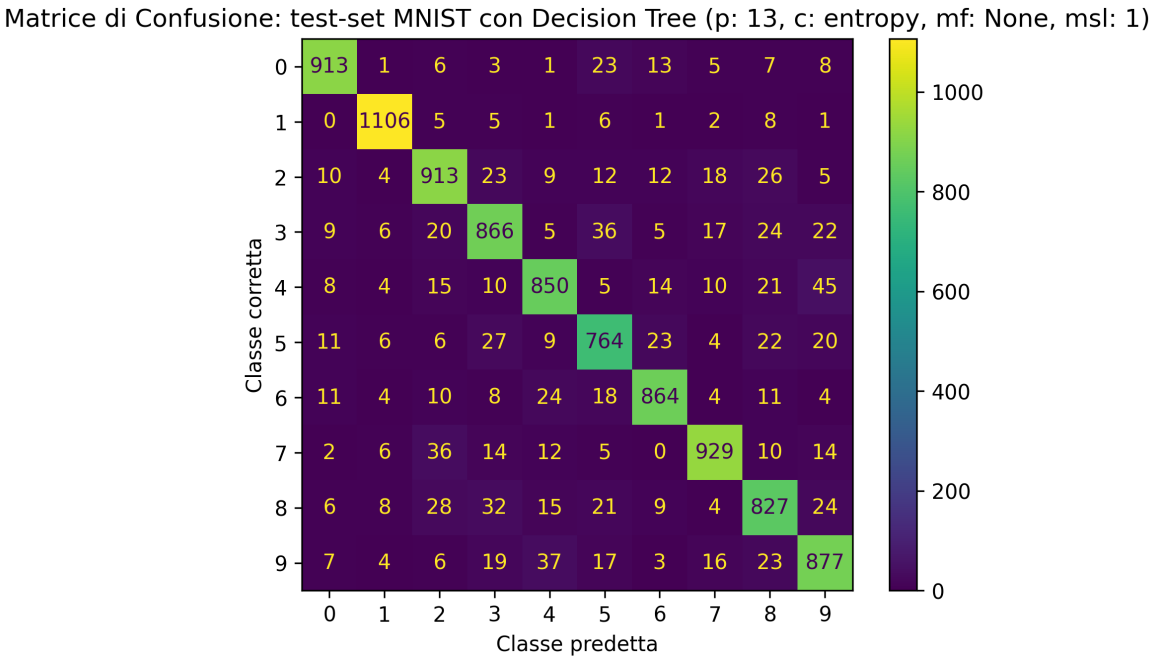

La matrice di confusione conferma ciò che viene mostrato nel report di classificazione la classe che corrisponde alla **cifra 1** mostra su circa **1135** campioni di **cifra 1 1106** vengono classificati correttamente, analogamente la classe che corrisponde alla **cifra 8** è quella che ottiene i peggiori risultati infatti su **974** campioni disponibili solo **827** vengono classificati correttamente. Risaltano all'occhio **32** campioni di **cifra 8** classificati come **cifra 3** e **28** campioni di **cifra 8** classificata come **cifra 2**

2) **Test del 2022-10-30 17:34:43 MNIST con Decision Tree (profondità: 17, c: gini, mf: 0.5, msl: 1)**

Report di classificazione

	precision	recall	f1-score	support
0	0.93	0.94	0.94	980
1	0.94	0.97	0.95	1135
2	0.88	0.85	0.86	1032
3	0.85	0.85	0.85	1010
4	0.88	0.90	0.89	982
5	0.84	0.83	0.84	892
6	0.92	0.91	0.92	958
7	0.91	0.91	0.91	1028
8	0.83	0.82	0.82	974
9	0.87	0.86	0.87	1009
accuracy			0.89	10000
macro avg	0.88	0.88	0.88	10000
weighted avg	0.88	0.89	0.88	10000

Dal report di classificazione notiamo che il nostro classificatore ottiene i migliori risultati classificando la **classe 1-> cifra 1** e i peggiori risultati di classificazione con la **classe 8 -> cifra 8**

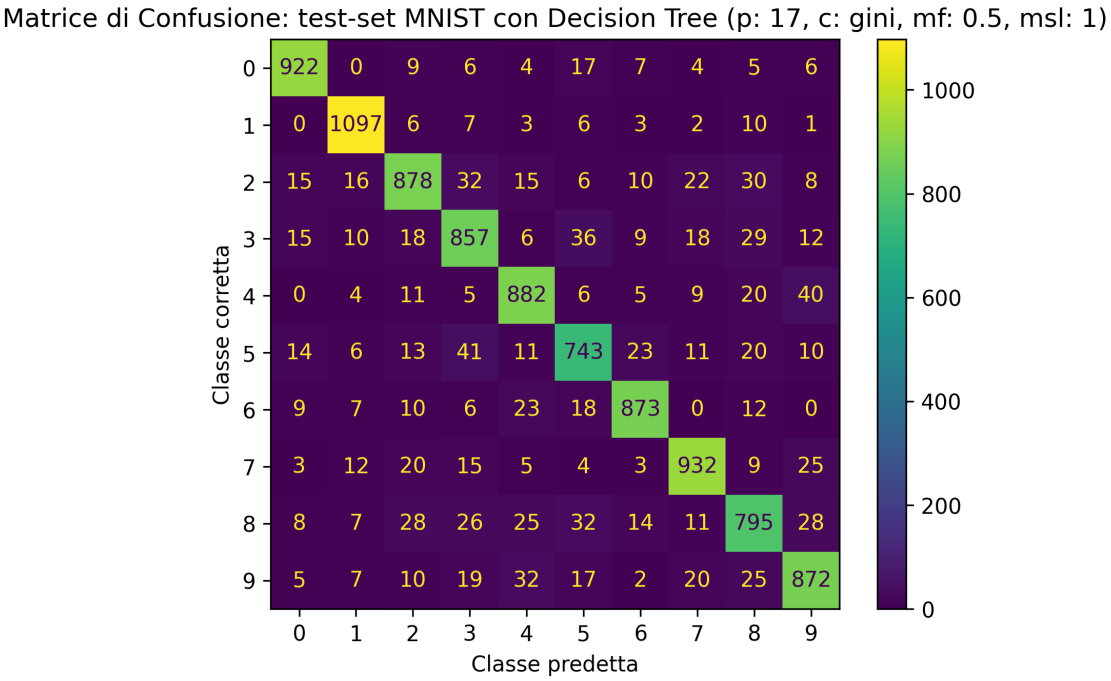

La matrice di confusione conferma ciò che viene mostrato nel report di classificazione la classe che corrisponde alla **cifra 1** mostra su circa **1135** campioni di **cifra 1 1097** vengono classificati correttamente, analogamente la classe che corrisponde alla **cifra 8** è quella che ottiene i peggiori risultati infatti su **974** campioni disponibili solo **795** vengono classificati correttamente. Risaltano all'occhio **32** campioni di **cifra 8** classificati come **cifra 5, 28** campioni di **cifra 8** classificata come **cifra 2** e **26** campioni di **cifra 8** classificati come **cifra 3**

3) **Test del 2022-11-01 17:24:20 MNIST con Decision Tree (profondità: 15, c: entropy, mf: 0.5, msl: 1)**

Report di classificazione

	precision	recall	f1-score	support
0	0.94	0.95	0.94	980
1	0.96	0.97	0.97	1135
2	0.88	0.86	0.87	1032
3	0.85	0.84	0.84	1010
4	0.88	0.86	0.87	982
5	0.84	0.83	0.83	892
6	0.91	0.90	0.91	958
7	0.90	0.91	0.90	1028
8	0.82	0.82	0.82	974
9	0.85	0.88	0.87	1009
accuracy			0.88	10000
macro avg	0.88	0.88	0.88	10000
weighted avg	0.88	0.88	0.88	10000

Dal report di classificazione notiamo che il nostro classificatore ottiene i migliori risultati classificando la **classe 1-> cifra 1** e i peggiori risultati di classificazione con la **classe 8 -> cifra 8**

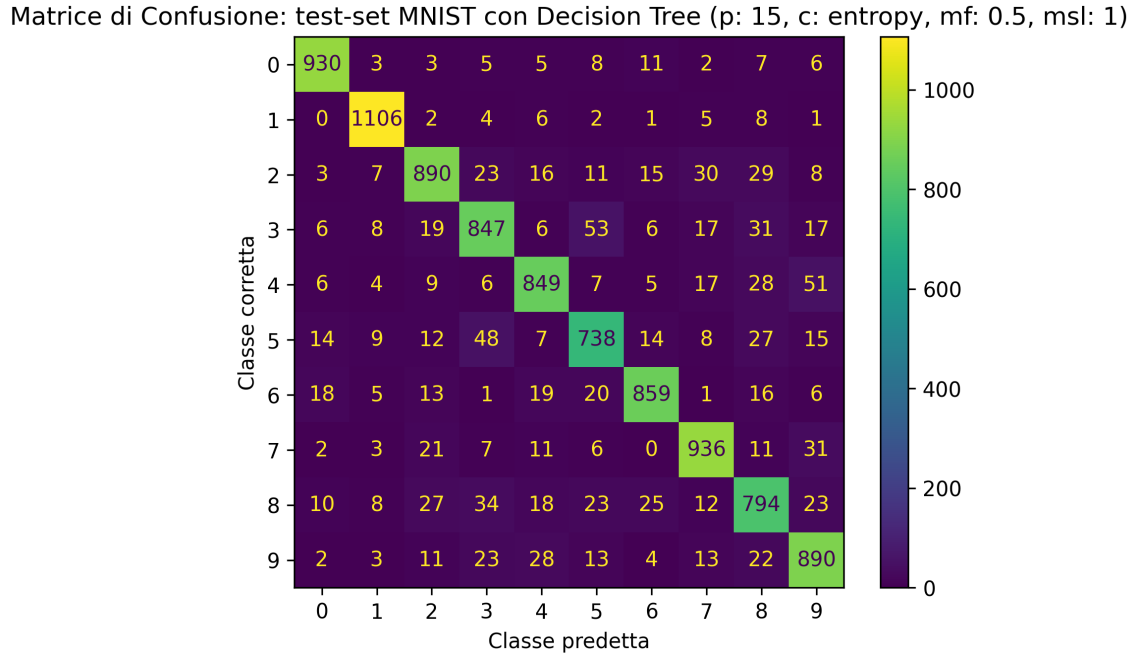

La matrice di confusione conferma ciò che viene mostrato nel report di classificazione la classe che corrisponde alla **cifra 1** mostra su circa **1135** campioni di **cifra 1 1106** vengono classificati correttamente, analogamente la classe che corrisponde alla **cifra 8** è quella che ottiene i peggiori risultati infatti su **974** campioni disponibili solo **794** vengono classificati correttamente. Risaltano all'occhio **34** campioni di **cifra 8** classificati come **cifra 3, 27** campioni di **cifra 8** classificata come **cifra 2** e **25** campioni di **cifra 8** classificati come **cifra 5**